Analyse des Résultats NER - Axes d'Amélioration du F1-Score

Date : 2025-01-15
Modèle analysé : `ner_camembert_20260115_100039_v1`
F1-Score actuel : 83.08%

Analyse d'erreurs : `nlp/results/error_analysis_ner_camembert_20260115_100039_v1.json`

📊 Résultats Actuels

Métriques Globales

Métrique	Valeur	Comparaison avec meilleur précédent
Precision	75.70%	+0.55% ✅
Recall	92.06%	+0.28% ✅
F1-Score	**83.08%**	+0.45% ✅
Accuracy	98.41%	+0.05% ✅

Métriques par Type d'Entité

DEPARTURE

- **Precision** : 75.88% → ~878 faux positifs estimés
- **Recall** : 92.90% → ~210 faux négatifs estimés
- **F1** : 83.53%

ARRIVAL

- **Precision** : 75.50% → ~761 faux positifs estimés
- **Recall** : 91.08% → ~229 faux négatifs estimés
- **F1** : 82.56%

🔍 Diagnostic Principal

Problème Identifié

Precision < Recall (75.70% vs 92.06%)

Le modèle génère **trop de faux positifs** :

- **159 faux positifs** sur 500 exemples testés (31.8%)
- **48 faux négatifs** sur 500 exemples testés (9.6%)
- Le modèle détecte des entités qui n'en sont pas
- Il est trop "généreux" dans ses prédictions
- Le recall est excellent (92%), donc le modèle détecte bien les vraies entités

Patterns de Faux Positifs Identifiés

D'après l'analyse d'erreurs (`error_analysis_ner_camembert_20260115_100039_v1.json`) :

1. **Tirets avec espaces** : **16 cas (16%)** 🔴
   - Exemples : "Bretenoux - birs", "Saint-Amand-Montrond - orrval", "Fontaines - Mercureyy"
   - Le modèle détecte "Ville - Ville" comme une seule entité au lieu de deux entités séparées
2. **Lettres isolées / mots très courts** : **6 cas (6%)** 🟡

- Exemples : "l" (3 fois), "la", "Ma", "champ"
- Le modèle détecte des lettres ou mots isolés comme des entités

3. **Préfixes inclus** : **4 cas (4%)** 🟡

   - Exemples : "l'aéroport d fretin", "la garre de capdennac", "l'aéropport de lisson"
   - Le modèle inclut encore parfois les préfixes dans les annotations (malgré les corrections)

4. **Pays** : **2 cas (2%)** 🟡

   - Exemples : "Tunisie", "turquie"
   - Le modèle détecte des pays comme des entités ARRIVAL

5. **Noms propres (probablement prénoms ou villes inconnues)** : **~28 cas (28%)** 🔴

   - Exemples : "Villars-les-Dombes", "Houdann", "bellvue", "guilléval", "victor"
   - Le modèle détecte des noms propres qui ne sont pas des gares/villes valides

6. **Autres** : **~103 cas (65%)**

   - Divers cas : villes avec fautes de frappe, noms composés, etc.

Impact sur le F1-Score

Le F1-Score est limité par la précision faible. Pour améliorer le F1 :

- **Option 1** : Augmenter la précision (réduire les faux positifs) → **RECOMMANDÉ**
- **Option 2** : Augmenter le recall (mais déjà à 92%, peu de marge)
- **Option 3** : Équilibrer les deux (meilleur compromis)

🎯 Axes d'Amélioration Prioritaires

1. Réduction des Faux Positifs (PRIORITÉ ABSOLUE) 🔴

Objectif : Passer de 75.70% à 80-85% de précision

A. Enrichir le Dataset avec des Exemples Négatifs

Problème : Le modèle n'a pas assez d'exemples où des noms propres similaires à des villes ne sont PAS des entités.

Solutions prioritaires (basées sur l'analyse d'erreurs) :

1. **Gérer les tirets avec espaces** (16% des FP) 🔴 **PRIORITÉ 1** :

   - Ajouter des patterns explicites : "VilleA - VilleB" où chaque ville est annotée séparément
   - Le tiret " - " doit être O (Outside), pas I-DEPARTURE/I-ARRIVAL
   - Exemples à ajouter :

     ```
     "Je vais de Paris – Lyon à Marseille"
     → "Paris" (DEPARTURE), "Lyon" (DEPARTURE), "Marseille" (ARRIVAL)
     → Le tiret " – " est O
     ```

2. **Ajouter des phrases avec noms propres non-annotés** (28% des FP) 🔴 **PRIORITÉ 2** :

   ```
   "Je vais voir mon ami Pierre à Paris"
   → "Pierre" ne doit PAS être annoté (c'est un prénom)
   → "Paris" doit être annoté comme ARRIVAL

   "Mon copain Victor habite à Lyon"
   → "Victor" ne doit PAS être annoté
   → "Lyon" doit être annoté comme ARRIVAL
   ```

3. **Ajouter des phrases avec pays/continents** (2% des FP) :

```
"Je vais en Tunisie depuis l'aéroport de Paris"
→ "Tunisie" ne doit PAS être annoté (c'est un pays)
→ "Paris" doit être annoté comme DEPARTURE
```

4. **Filtrer les lettres isolées** (6% des FP) :
   - Ajouter une règle de post-processing : rejeter les entités de 1-2 caractères
   - Ou enrichir le dataset avec des exemples où "l", "la", "le" apparaissent mais ne sont pas annotés
5. **Ajouter des phrases avec villes mentionnées hors contexte de trajet** :

```
"Paris est une belle ville"
→ "Paris" ne doit PAS être annoté (pas un trajet)
```

Impact estimé : +5-8% de précision (en ciblant les 16% de tirets + 28% de noms propres)

B. Post-Processing Intelligent

Solution : Filtrer les prédictions avec une liste de validation

1. **Validation par liste de gares valides** :
   - Charger `dataset/shared/gares-francaises.json`
   - Filtrer les entités prédites qui ne sont pas dans la liste
   - Garder uniquement les entités validées
   - **Impact** : Éliminer ~28% des FP (noms propres qui ne sont pas des gares)
2. **Filtrage des lettres isolées** :
   - Rejeter automatiquement les entités de 1-2 caractères
   - **Impact** : Éliminer ~6% des FP
3. **Filtrage des pays** :
   - Liste de pays à exclure : Tunisie, Turquie, Inde, etc.
   - **Impact** : Éliminer ~2% des FP
4. **Validation contextuelle** :
   - Vérifier que l'entité est dans un contexte de trajet
   - Exemples de contextes valides : "de X à Y", "depuis X", "vers Y"
   - Rejeter les entités isolées sans contexte

Impact estimé total : +4-6% de précision

C. Ajustement des Hyperparamètres

Solutions :

1. **Augmenter la régularisation** :
   - `weight_decay` : 0.0 → 0.01 (réduit l'overfitting)
   - Impact : +1-2% précision
2. **Réduire légèrement le learning rate** :
   - `learning_rate` : 2e-05 → 1.5e-05
   - Impact : +0.5-1% précision
3. **Early stopping basé sur la précision** :

- Arrêter l'entraînement quand la précision sur validation ne s'améliore plus
- Impact : +0.5-1% précision

Impact estimé : +2-4% de précision

---

2. Réduction des Faux Négatifs (PRIORITÉ SECONDAIRE) 🟡

Objectif : Maintenir le recall à ~92% tout en améliorant la précision

A. Enrichir le Dataset avec des Variantes

Solutions :

1. **Ajouter des patterns avec fautes de frappe** :
   - "Pariss" au lieu de "Paris"
   - "Lyonn" au lieu de "Lyon"
2. **Ajouter des patterns avec abréviations** :
   - "Paris Gare du Nord" → "Paris GDN"
   - "Lyon Part-Dieu" → "Lyon PD"
3. **Ajouter des patterns avec variations de casse** :
   - "PARIS", "paris", "PaRiS"

Impact estimé : Maintien du recall à ~92%

---

3. Techniques Avancées (PRIORITÉ TERTIAIRE) 🟢

A. Focal Loss

Solution : Utiliser Focal Loss au lieu de Cross-Entropy Loss

- Pénalise plus les faux positifs
- Impact estimé : +2-3% précision

B. Model Ensembles

Solution : Combiner plusieurs modèles entraînés avec différentes initialisations

- Impact estimé : +1-2% F1

C. Fine-tuning avec Données Ciblées

Solution : Réentraîner sur un dataset enrichi avec les cas problématiques identifiés

- Impact estimé : +3-5% F1

📈 Objectifs Réalistes

Court Terme (1-2 semaines)

Objectifs :

- Precision : 75.70% → **80-82%** (+4-6%)
- Recall : 92.06% → **91-92%** (maintenir)
- **F1-Score : 83.08% → 85-87%** (+2-4%)

Actions :

1. ✅ Enrichir le dataset avec exemples négatifs (noms propres, pays, etc.)
2. ✅ Implémenter post-processing avec validation par liste de gares

3. ✅ Ajuster les hyperparamètres (weight_decay, learning_rate)

Moyen Terme (1 mois)

Objectifs :

- Precision : **82-85%**
- Recall : **91-92%**
- **F1-Score : 86-88%**

Actions :

1. ✅ Itérer sur le dataset basé sur l'analyse d'erreurs
2. ✅ Implémenter Focal Loss
3. ✅ Optimiser les hyperparamètres avec grid search

Long Terme (si nécessaire)

Objectifs :

- Precision : **85-90%**
- Recall : **90-92%**
- **F1-Score : 87-91%**

Actions :

1. ✅ Model ensembles
2. ✅ Fine-tuning avancé
3. ✅ Techniques de data augmentation sophistiquées

🛠️ Plan d'Action Recommandé

Phase 1 : Analyse des Erreurs ✅ FAIT

1. ✅ **Analyse d'erreurs exécutée** :
   - Fichier : `nlp/results/error_analysis_ner_camembert_20260115_100039_v1.json`
   - 159 faux positifs identifiés sur 500 exemples
   - 48 faux négatifs identifiés
2. ✅ **Patterns identifiés** :
   - **Tirets avec espaces** : 16 cas (16%) - PRIORITÉ 1
   - **Noms propres** : ~28 cas (28%) - PRIORITÉ 2
   - **Lettres isolées** : 6 cas (6%)
   - **Préfixes inclus** : 4 cas (4%)
   - **Pays** : 2 cas (2%)

Phase 2 : Enrichissement du Dataset (1-2 jours) 🔴 PRIORITÉ

1. **Corriger les patterns avec tirets** (16% des FP) :
   - Modifier le générateur pour annoter correctement "VilleA - VilleB"
   - Chaque ville doit être annotée séparément
   - Le tiret " - " doit être O (Outside)
   - Exemple : "Paris - Lyon" → "Paris" (DEPARTURE), "Lyon" (ARRIVAL), "-" (O)
2. **Ajouter des exemples négatifs** :
   - **Noms propres (prénoms)** : "Mon ami Pierre", "Je vais voir Victor"
   - **Pays** : "Je vais en Tunisie", "Je pars pour la Turquie"
   - **Noms de lieux non-gares** : "restaurant Le Paris", "monument de Lyon"

- **Villes mentionnées hors contexte** : "Paris est belle", "J'aime Lyon"

3. **Régénérer le dataset** :

```
python dataset/generators/nlp/dataset_generator.py
```

Phase 3 : Post-Processing (1 jour) 🔴 PRIORITÉ

1. **Implémenter la validation par liste de gares** :
   - Charger `dataset/shared/gares-francaises.json`
   - Filtrer les entités prédites qui ne sont pas dans la liste
   - **Impact** : Éliminer ~28% des FP (noms propres non-gares)
2. **Filtrage des lettres isolées** :
   - Rejeter les entités de 1-2 caractères
   - **Impact** : Éliminer ~6% des FP
3. **Filtrage des pays** :
   - Liste de pays à exclure
   - **Impact** : Éliminer ~2% des FP
4. **Implémenter la validation contextuelle** :
   - Vérifier que l'entité est dans un contexte de trajet
   - Rejeter les entités isolées sans contexte
5. **Tester sur le dataset de test**

Phase 4 : Réentraînement (1 jour)

1. **Ajuster les hyperparamètres**
2. **Réentraîner le modèle**
3. **Comparer les résultats**

📝 Notes Importantes

- **Le recall est excellent (92%)** : Ne pas le sacrifier en améliorant la précision
- **L'objectif est d'équilibrer** : Precision ≈ Recall pour un F1 optimal
- **Itération continue** : Améliorer le dataset basé sur les erreurs identifiées
- **Qualité > Quantité** : Mieux vaut moins d'exemples mais bien annotés

---

🔗 Ressources

- Script d'analyse d'erreurs : `scripts/analyze_ner_errors.py`
- Générateur de dataset : `dataset/generators/nlp/dataset_generator.py`
- Liste des gares : `dataset/shared/gares-francaises.json`
- Journal du projet : `nlp/JOURNAL.md`